

Estimação Inteligente de Idade de Telespectadores para Aplicações de Sugestão de Conteúdo em *Smart TVs*

Trabalho de Conclusão de Curso I

por

Nicoli P. Araújo, Elloá B. Guedes

{npda.eng, ebgcosta, }@uea.edu.br

do

Núcleo de Computação
Escola Superior de Tecnologia
Universidade do Estado do Amazonas
Manaus – Amazonas – Brasil

Outline

1. Apresentação
2. Fundamentação Teórica
3. Trabalhos Relacionados
4. Conjunto de Dados
5. Resultados
6. Considerações Finais

Contextualização e Motivação

❖ *Smart TVs*

- ❖ Conexão à internet
- ❖ Transmissão de conteúdos advindos de outros dispositivos eletrônicos

❖ **PNAD 2015**

- ❖ Responsáveis por 68,2% do total de televisores vendidos no primeiro semestre de 2017

❖ Causas:

- ❖ Benefícios resultantes do uso de *Smart TVs* quando comparadas aos aparelhos convencionais
- ❖ Encerramento da transmissão de sinal analógico da televisão aberta
- ❖ Copa do Mundo 2018
- ❖ Tecnologia 4K

Contextualização e Motivação

❖ **Recomendação de Conteúdo:**

- ❖ Dificuldades práticas
- ❖ *Smart* TVs possuem dispositivos para captura de imagens, como câmeras
- ❖ Sistemas inteligentes de identificação de características
- ❖ Recomendação de conteúdo
- ❖ Controle Parental

Objetivos

- ✦ **Objetivo Geral:** Desenvolvimento de estratégias inteligentes, baseadas na utilização de técnicas de *Deep Learning*, para estimação da idade de telespectadores a partir de fotografias faciais
- ✦ **Objetivos Específicos:**
 1. Referencial teórico sobre redes neurais convolucionais
 2. *Smart TVs* possuem dispositivos para captura de imagens, como câmeras
 3. Consolidar uma base de dados
 4. Identificar tecnologias adequadas
 5. Propor, treinar e testar diferentes estimadores de idade
 6. Avaliar comparativamente os estimadores propostos

Justificativas

- Melhor experiência de provimento de conteúdo e de configurações personalizadas
 - **Controle Parental**
- Prática e a proposição de soluções envolvendo *Machine Learning*
- Laboratório de Sistemas Inteligentes (LSI)

Metodologia

- ❖ Fundamentação teórica sobre Machine Learning
- ❖ Fluxo de atividades de machine learning (Marsland)
 - ❖ Consolidar uma base de dados
 - ❖ Proposição de diferentes modelos de redes neurais convolucionais
 - ❖ Treinamento das redes neurais convolucionais
 - ❖ Teste das redes
 - ❖ Comparação de métricas de desempenho
- ❖ Escrita da proposta e do projeto final do trabalho de conclusão de curso

Cronograma

Tabela 1: Cronograma de atividades levando em consideração os dez meses (de 02/2018 a 12/2018) para a realização do TCC.

	2018										
	02	03	04	05	06	07	08	09	10	11	12
Escrita da Proposta	X	X	X	X	X						
Fundamentação Teórica sobre ML	X	X	X	X							
Consolidação da Base de Dados		X	X								
Proposição de Modelos de CNNs				X	X	X	X	X			
Defesa da Proposta					X						
Escrita do Trabalho Final						X	X	X	X	X	X
Treinamento das CNNs					X	X	X	X	X	X	
Teste das CNNs					X	X	X	X	X	X	X
Comparação de Métricas de Desempenho						X	X	X	X	X	X
Defesa do Trabalho Final											X

Outline

1. Apresentação
2. Fundamentação Teórica
3. Trabalhos Relacionados
4. Conjunto de Dados
5. Resultados
6. Considerações Finais

Smart TVs

- ❖ Capacidades interativas
- ❖ Conexão à internet
- ❖ Conteúdo de mídia transmitido a partir de outros dispositivo





Programa Silvio Santos

O Programa Silvio Santos traz várias horas de diversão, games, convidados famosos, brincadeiras com o auditório, além de boas gargalhadas com o melhor apresentador da TV, Silvio Santos.

PROGRAMA
SILVIO SANTOS



CANAIS



❖ PNAD 2015

- ❖ 103 milhões de aparelhos de televisões em residências e pontos comerciais
- ❖ 16 milhões de *Smart TVs*
- ❖ 94% destas *Smart TVs* foram adquiridas entre 2014 e 2015
- ❖ 68,2% do total de televisores vendidos no primeiro semestre de 2017

Smart TVs

- ❖ Benefícios resultantes do uso de *Smart*
- ❖ Encerramento da transmissão de sinal analógico da televisão aberta
- ❖ Copa do Mundo 2018
- ❖ Tecnologia 4K

Classificação Indicativa

- ❖ Sistema de garantias dos direitos da criança e do adolescente
- ❖ Reserva-se o direito final aos pais e responsáveis
- ❖ Órgão responsável: Cocind, vinculada ao Ministério da Justiça
- ❖ Análise de classificação indicativa
 - ❖ Grau de incidência de conteúdos impróprios

Machine Learning

- ❖ Estudo sistemático de algoritmos e sistemas que são capazes de melhorar seu desempenho com a experiência
- ❖ Modelo ou função que mapeie as instâncias do espaço de entrada para o de saída
- ❖ Paradigmas de Aprendizado
 - ❖ Aprendizado Supervisionado
 - ❖ Aprendizado Não-Supervisionado
 - ❖ Aprendizado por Reforço
- ❖ Tarefas de Aprendizado
 - ❖ Classificação
 - ❖ Regressão

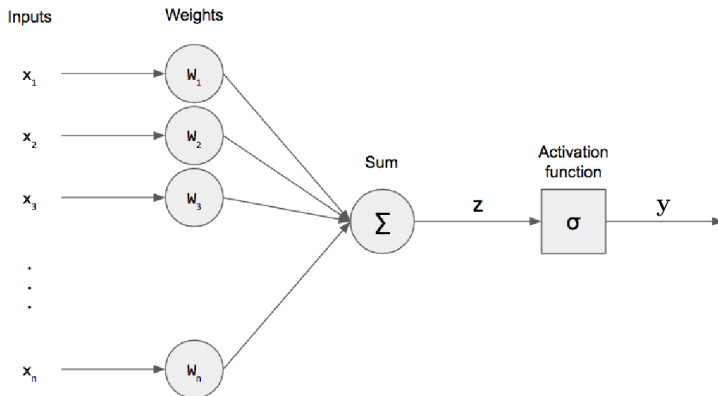
Redes Neurais Artificiais

- ❖ Cérebro humano
- ❖ Neurônios: unidades de processamento simples
- ❖ Capacidade de capturar tendências
- ❖ Generalização

Redes Neurais Artificiais

■ McCulloch e Pitts

Figura 3: Representação de um neurônio artificial




Redes Neurais Artificiais

- ❖ Perceptron de Rosenblatt (1958)
 - ❖ Algoritmo de aprendizado
 - ❖ Endereçar apenas problemas linearmente separáveis

Redes Neurais Artificiais


Figura 4: Arquiteturas populares de RNAs.




Single Layer Perceptron






Radial Basis Network (RBN)



Multi Layer Perceptron

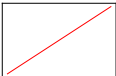

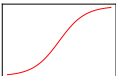



Recurrent Neural Network



Redes Neurais Artificiais

Tabela 2: Exemplos de funções de ativação

Nome	Gráfico	Equação	Intervalo
Identidade ou Linear		$\sigma(z) = z$	$(-\infty, +\infty)$
Tangente Hiperbólica		$\sigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	$(-1, 1)$
Sigmoide ou Logística		$\sigma(z) = \frac{1}{1 + e^{-x}}$	$(0, 1)$
Unidade Linear Retificada		$\sigma(z) = \max(0, z)$	$[0, \infty)$

Redes Neurais Artificiais

- ❖ Hiperparâmetros de uma RNA
 - ❖ Taxa de aprendizado
 - ❖ Funções de ativação
 - ❖ Arquitetura da rede
 - ❖ *batch size*
 - ❖ Número de épocas

Redes Neurais Artificiais

- ❖ Algoritmo de treinamento de uma RNA
- ❖ Entrada: Conjuntos de exemplos e respectivos rótulos (X, Y) , rede neural a ser treinada, número de épocas e , taxa de aprendizado η e *batch size* b .
- ❖ Saída: Rede neural treinada.
 1. Inicialização dos vetores de pesos w e *bias* b
 2. Para cada *batch* $= 1, \dots, b$ do conjunto de dados:
 - 2.1 Fase *forward*: Calcular previsões \hat{y} e custos J .
 - 2.2 Fase *backwards*: Calcular gradientes dos pesos ∇_{w^c} e *bias* ∇_{b^c}
 - 2.3 Atualizar valores dos pesos e *bias* a partir do gradiente descendente.

Deep Learning

- ❖ Capacidade de representar e reconhecer características sucessivamente complexas
- ❖ Adição de níveis ou camadas de operações não-lineares
- ❖ Resolver problemas complexos com um desempenho cada vez maior
 - ❖ Aumento recente da quantidade de dados disponíveis sobre temas complexos
 - ❖ Aumento da disponibilidade de recursos computacionais para executar modelos mais robustos


Deep Learning

Evolução de profundidade, taxa de erro e número de parâmetros das redes neurais profundas com o passar dos anos

Estimação Inteligente de Idade de Telespectadores

para A

art TVs



Deep Learning

❖ Breve Histórico


- ❖ (1950) Proposição de modelos lineares simples: McCulloch e Pitts; Perceptron
- ❖ (1980) Interconexão entre vários neurônios e a proposição do algoritmo *back-propagation* para ajuste de pesos no treinamento das RNAs
 - ▶ LeNet
- ❖ (2006) Modelos compostos de várias camadas sucessivas de operações não lineares utilizados para o aprendizado de determinada tarefa

Deep Learning

- ❖ *ImageNet Large Scale Visual Recognition Challenge (ILSVRC)*
 - ❖ Imagenet
 - ❖ 14 milhões de imagens de 21 mil categorias organizadas hierarquicamente
 - ❖ Erro top-5

Deep Learning

Figura 6: Evolução do erro dos modelos vencedores da competição ILSVRC pela profundidade das redes neurais



Redes Neurais Convolucionais


- ❖ Topologia bem definida e estrutura em grade
- ❖ Operações de convolução em pelo menos uma de suas camadas
- ❖ Destaca-se no reconhecimento de padrões em dados de alta dimensionalidade

Redes Neurais Convolucionais

❖ Convolução


$$S(i, j) = I(i, j) * K(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \quad (1)$$

Figura 7: Papel das camadas convolucionais e *feature maps* nas CNNs.



Redes Neurais Convolucionais

Figura 8: Componentes de uma camada de uma rede neural convolucional.



Redes Neurais Convolucionais

- ❖ Hiperparâmetros de uma CNN
 - ❖ Pooling
 - ❖ Padding
 - ❖ Strides

Modelos Canônicos de Redes Neurais

- ❖ Arquiteturas que trouxeram contribuições importantes
- ❖ Comuns ainda hoje no cenário de DL

Modelos Canônicos de Redes Neurais

❖ LeNet (1998)

- ❖ Conjunto de dados *Modified National Institute of Standards and Technology* (MNIST)
- ❖ Imagens em escala de cinza de tamanho 32×32
- ❖ Amplamente utilizada por bancos

IMAGEM DA LENET

Modelos Canônicos de Redes Neurais

❖ AlexNet (2012)

- ❖ Primeira CNN ganhadora do desafio ILSVRC
- ❖ Imagens de 1000 categorias da ImageNet
- ❖ Erro top-5 igual a 15.4%
- ❖ Treinamento: duas GPU GTX 580 por 5 a 6 dias

IMAGEM DA AlexNet

Modelos Canônicos de Redes Neurais

❖ VGG (2014)

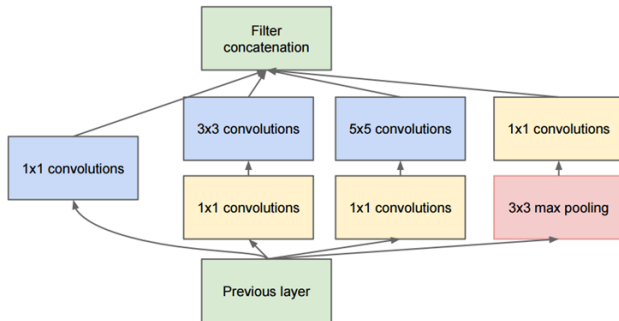
- ❖ Erro top-5 de 7.3%
- ❖ Treinamento em 4 GPUs Nvidia Titan Black por duas a três semanas
- ❖ Erro top-5 igual a 15.4%

IMAGEM DA VGG

Modelos Canônicos de Redes Neurais

- ❖ Inception ou GoogLeNet (2014)
 - ❖ 22 camadas convolucionais
 - ❖ Treinamento em algumas GPUs de alta performance por uma semana
 - ❖ Erro top-5 de 6.7%

Figura 9: Bloco Inception da CNN GoogLeNet




Modelos Canônicos de Redes Neurais

❖ ResNet (2015)

- ❖ Total de 152 camadas
- ❖ Treinamento em 8 GPUs por duas a três semanas
- ❖ Erro top-5 de 3.6%


Figura 10: Bloco Residual da CNN ResNet.



❖ ResNet (2015)

- ❖ Total de 152 camadas
- ❖ Treinamento em 8 GPUs por duas a três semanas
- ❖ Erro top-5 de 3.6%

Figura 11: Bloco Residual da CNN ResNet.



Outline

1. Apresentação
2. Fundamentação Teórica
- 3. Trabalhos Relacionados**
4. Conjunto de Dados
5. Resultados
6. Considerações Finais

Trabalhos Relacionados

❖ **Lima & Guedes** et al. (2015, 2016)

- ❖ Previsão de precipitações um dia à frente
- ❖ Tarefa de classificação
- ❖ *Time Delay Neural Networks*
- ❖ Dados de 1970 a 2010
- ❖ Acurácia: 99.7%

❖ **Limitação:**

- ❖ Ausência do volume associado às precipitações

❖ **Vantagens:**

- ❖ Dados advindos de estações meteorológicas
- ❖ Utilização de dados defasados
- ❖ Tipo de redes neurais considerado

Outline

1. Apresentação
2. Fundamentação Teórica
3. Trabalhos Relacionados
- 4. Conjunto de Dados**
5. Resultados
6. Considerações Finais

Conjunto de Dados

- ❖ **Período de dados:** 1950 a 2015
 - ❖ 65 anos de dados
 - ❖ Volume mensal de precipitações
 - ❖ Departamento de Meteorologia da UEA

- ❖ Análise descritiva dos dados
 - ❖ Diferentes características a cada mês
 - ❖ Presença de *outliers*
 - ❖ Ampla dispersão, etc.

Conjunto de Dados

- ✦ Mês com maior volume de precipitação: **Março: 321.58mm**
- ✦ Mês com menor volume de precipitação: **Agosto: 54.56mm**

Conjunto de Dados

- ❖ **Índices Climáticos:** Niño 1+2, 3, 3.4 e 4
 - ❖ Relação com os fenômenos El Niño e La Niña
 - ❖ Influência na variabilidade das chuvas na bacia amazônica

- ❖ **TSA:** Temperatura na Superfície do Atlântico

Outline

1. Apresentação
2. Fundamentação Teórica
3. Trabalhos Relacionados
4. Conjunto de Dados
- 5. Resultados**
6. Considerações Finais

Resultados

- Identificação de uma rede neural para previsão do volume de precipitações em cada mês do ano
- Acurácia média: 92,16%
- Não foi possível identificar um único modelo de RNAs capaz de capturar todas as características de todos os meses
 - Contraste com o trabalho de Lima & Guedes

Resultados

Tabela 3: Redes neurais com maior acurácia para previsão do volume de precipitações em Manaus nos diferentes meses do ano.

Mês	Arquitetura	Função de Ativação	Taxa de Aprendizado	Taxa de Decréscimo	Acurácia
1	(37, 9, 1)	Tangente Hiperbólica	0.0001	0.003	0.93
2	(37, 7, 1)	Sigmoidal	0.0001	0.003	0.93
3	(37, 8, 4, 1)	Tangente Hiperbólica	0.0001	0.001	1.00
4	(37, 4, 1)	Tangente Hiperbólica	0.0001	0.001	0.87
5	(37, 8, 1)	Tangente Hiperbólica	0.0100	0.001	0.93
6	(37, 5, 1)	Tangente Hiperbólica	0.0100	0.003	0.87
7	(37, 8, 1)	Tangente Hiperbólica	0.0100	0.003	0.93
8	(37, 6, 6, 1)	Sigmoidal	0.0001	0.003	0.93
9	(37, 8, 4, 1)	Tangente Hiperbólica	0.0001	0.003	1.00
10	(37, 8, 1)	Tangente Hiperbólica	0.0001	0.003	0.87
11	(37, 8, 1)	Tangente Hiperbólica	0.0001	0.001	0.93
12	(37, 9, 3, 1)	Tangente Hiperbólica	0.0100	0.003	0.87

Outline

1. Apresentação
2. Fundamentação Teórica
3. Trabalhos Relacionados
4. Conjunto de Dados
5. Resultados
6. Considerações Finais

Considerações Finais

Contribuições

- ❖ Utilização de Aprendizagem de Máquina para previsão de precipitações
- ❖ Defasamento temporal e utilização de índices climáticos
- ❖ Identificação de 12 RNAs, sendo uma para cada mês do ano
- ❖ Acurácia média: 92,16%

Considerações Finais

Contribuições

- ❖ Utilização de Aprendizagem de Máquina para previsão de precipitações
- ❖ Defasamento temporal e utilização de índices climáticos
- ❖ Identificação de 12 RNAs, sendo uma para cada mês do ano
- ❖ Acurácia média: 92,16%

Trabalhos Futuros

- ❖ Comparar outras técnicas de Aprendizagem de Máquina
- ❖ Previsão do volume anual de precipitações

