

Utilização de Redes Neurais para Previsão de Precipitação em Manaus, Amazonas

IV Escola Regional de Informática – ERIN 2017

por

Nicoli Araújo, Elloá B. Guedes, Maria B. Olivera
{npda.eng, ebgcosta, mloliveira}@uea.edu.br

do

Núcleo de Computação
Escola Superior de Tecnologia
Universidade do Estado do Amazonas
Manaus – Amazonas – Brasil

Outline

1. Apresentação

2. Trabalhos Relacionados

3. Conjunto de Dados

4. Metodologia

5. Resultados

6. Considerações Finais

Contextualização e Motivação

✦ Previsão de precipitação

- ✦ Implicações: agricultura, enchentes, recursos hídricos, etc.
- ✦ Fatores: localização geográfica, topografia, características climáticas, etc.

✦ **Manaus:** Clima e precipitações

- ✦ Köppen: Tropical de monções
- ✦ Equatorial quente e úmido



Contextualização e Motivação

- ❖ **Redes Neurais:** modelo de Aprendizado de Máquina (AM)
 - ❖ Elaboração de soluções empíricas
 - ❖ Aprendizado a partir de dados
 - ❖ Inspirado no sistema nervoso humano
- ❖ Trabalhos anteriores **Lima & Guedes**
 - ❖ Utilização de RNAs para previsão da ocorrência de precipitações em Manaus um dia à frente
 - ❖ Ausência de estimativas do volume de precipitações

Contextualização e Motivação

- ❖ **Redes Neurais:** modelo de Aprendizado de Máquina (AM)
 - ❖ Elaboração de soluções empíricas
 - ❖ Aprendizado a partir de dados
 - ❖ Inspirado no sistema nervoso humano
- ❖ Trabalhos anteriores **Lima & Guedes**
 - ❖ Utilização de RNAs para previsão da ocorrência de precipitações em Manaus um dia à frente
 - ❖ Ausência de estimativas do volume de precipitações

Objetivo do Trabalho

Prever o **volume mensal** de precipitações em Manaus, Amazonas utilizando Redes Neurais Artificiais

Outline

1. Apresentação

2. Trabalhos Relacionados

3. Conjunto de Dados

4. Metodologia

5. Resultados

6. Considerações Finais

Trabalhos Relacionados

✦ **Lima & Guedes** et al. (2015, 2016)

- ✦ Previsão de precipitações um dia à frente
- ✦ Tarefa de classificação
- ✦ *Time Delay Neural Networks*
- ✦ Dados de 1970 a 2010
- ✦ Acurácia: 99.7%

✦ **Limitação:**

- ✦ Ausência do volume associado às precipitações

✦ **Vantagens:**

- ✦ Dados advindos de estações meteorológicas
- ✦ Utilização de dados defasados
- ✦ Tipo de redes neurais considerado

Outline


1. Apresentação
2. Trabalhos Relacionados
- 3. Conjunto de Dados**
4. Metodologia
5. Resultados
6. Considerações Finais

Conjunto de Dados

- ❖ **Período de dados:** 1950 a 2015
 - ❖ 65 anos de dados
 - ❖ Volume mensal de precipitações
 - ❖ Departamento de Meteorologia da UEA

- ❖ Análise descritiva dos dados
 - ❖ Diferentes características a cada mês
 - ❖ Presença de *outliers*
 - ❖ Ampla dispersão, etc.

Conjunto de Dados



- Mês com maior volume de precipitação: **Março: 321.58mm**
- Mês com menor volume de precipitação: **Agosto: 54.56mm**

Conjunto de Dados

- ❖ **Índices Climáticos:** Niño 1+2, 3, 3.4 e 4
 - ❖ Relação com os fenômenos El Niño e La Niña
 - ❖ Influência na variabilidade das chuvas na bacia amazônica

- ❖ **TSA:** Temperatura na Superfície do Atlântico

Outline

1. Apresentação
2. Trabalhos Relacionados
3. Conjunto de Dados
- 4. Metodologia**
5. Resultados
6. Considerações Finais

Metodologia

- ❖ Utilização de Séries Temporais
 - ❖ Janela de tempo: 6 meses
 - ❖ Precipitação, Índices Niño e TSA
 - ❖ *Time Delay Neural Networks*
 - ❖ Atributos de entrada: 36

- ❖ Normalização dos dados
 - ❖ $\tilde{N}(0, 1)$
 - ❖ Amortizar os dados na mesma escala
 - ❖ Precipitação e índices Niño

❖ Cálculo da **anomalia**

- ❖ Diferença em relação à média histórica: $x_i - \bar{x}$
- ❖ Muito adotada na Meteorologia
- ❖ Captura noção de tendência

❖ Cálculo da **anomalia**

- ❖ Diferença em relação à média histórica: $x_i - \bar{x}$
- ❖ Muito adotada na Meteorologia
- ❖ Captura noção de tendência

Abordagem

Prever a classificação da anomalia mensal do volume de precipitações em Manaus, Amazonas

Metodologia

- ❖ Dimensionamento das redes neurais
- ❖ Camada de entrada: $N_i = 36$
- ❖ Camada de saída: $N_o = 1$
- ❖ Camadas ocultas: 1 a 2
- ❖ Neurônios nas camadas ocultas: regra da pirâmide geométrica

$$N_h = \alpha \sqrt{N_i \cdot N_o}, \quad (1)$$

- ❖ com $0.5 \leq \alpha \leq 2$
- ❖ **Resultado:** $3 \leq N_h \leq 12$

❖ Outros parâmetros:

- ❖ Função de Ativação: Logística ou Tangente Hiperbólica
- ❖ Épocas: 2000
- ❖ Taxa de Aprendizagem Inicial: 0.001 ou 0.003
- ❖ Fração de Decréscimo: 0.0001 ou 0.01

Resultado do Dimensionamento

136 redes neurais a serem treinadas e testadas para cada mês do ano!

Metodologia

❖ Partição do conjunto de dados:

- ❖ De 1950 a 2000 – 77%: Treinamento
- ❖ 10% dos dados de treinamento reservados para validação
- ❖ De 2001 a 2015 – 23%: Teste

❖ Métrica de performance: Acurácia

$$\text{Acuracia}(\%) = \frac{100}{n} \sum_{t=1}^n 1 - |y_t - p_t| \quad (2)$$

Outline

1. Apresentação
2. Trabalhos Relacionados
3. Conjunto de Dados
4. Metodologia
- 5. Resultados**
6. Considerações Finais

Resultados

- Identificação de uma rede neural para previsão do volume de precipitações em cada mês do ano
- Acurácia média: 92,16%
- Não foi possível identificar um único modelo de RNAs capaz de capturar todas as características de todos os meses
 - Contraste com o trabalho de Lima & Guedes

Resultados

Tabela 1: Redes neurais com maior acurácia para previsão do volume de precipitações em Manaus nos diferentes meses do ano.

Mês	Arquitetura	Função de Ativação	Taxa de Aprendizado	Taxa de Decréscimo	Acurácia
1	(37, 9, 1)	Tangente Hiperbólica	0.0001	0.003	0.93
2	(37, 7, 1)	Sigmoidal	0.0001	0.003	0.93
3	(37, 8, 4, 1)	Tangente Hiperbólica	0.0001	0.001	1.00
4	(37, 4, 1)	Tangente Hiperbólica	0.0001	0.001	0.87
5	(37, 8, 1)	Tangente Hiperbólica	0.0100	0.001	0.93
6	(37, 5, 1)	Tangente Hiperbólica	0.0100	0.003	0.87
7	(37, 8, 1)	Tangente Hiperbólica	0.0100	0.003	0.93
8	(37, 6, 6, 1)	Sigmoidal	0.0001	0.003	0.93
9	(37, 8, 4, 1)	Tangente Hiperbólica	0.0001	0.003	1.00
10	(37, 8, 1)	Tangente Hiperbólica	0.0001	0.003	0.87
11	(37, 8, 1)	Tangente Hiperbólica	0.0001	0.001	0.93
12	(37, 9, 3, 1)	Tangente Hiperbólica	0.0100	0.003	0.87

Outline

1. Apresentação
2. Trabalhos Relacionados
3. Conjunto de Dados
4. Metodologia
5. Resultados
6. Considerações Finais

Considerações Finais

Contribuições

- ❖ Utilização de Aprendizagem de Máquina para previsão de precipitações
- ❖ Defasamento temporal e utilização de índices climáticos
- ❖ Identificação de 12 RNAs, sendo uma para cada mês do ano
- ❖ Acurácia média: 92,16%

Considerações Finais

Contribuições

- ❖ Utilização de Aprendizagem de Máquina para previsão de precipitações
- ❖ Defasamento temporal e utilização de índices climáticos
- ❖ Identificação de 12 RNAs, sendo uma para cada mês do ano
- ❖ Acurácia média: 92,16%

Trabalhos Futuros

- ❖ Comparar outras técnicas de Aprendizagem de Máquina
- ❖ Previsão do volume anual de precipitações

Utilização de Redes Neurais para Previsão de Precipitação em Manaus, Amazonas

IV Escola Regional de Informática – ERIN 2017

por

Nicoli Araújo, Elloá B. Guedes, Maria B. Olivera
{npda.eng, ebgcosta, mloliveira}@uea.edu.br

do

Núcleo de Computação
Escola Superior de Tecnologia
Universidade do Estado do Amazonas
Manaus – Amazonas – Brasil