

NICOLI PINHEIRO DE ARAUJO

**ESTIMAÇÃO INTELIGENTE DE IDADE DE TELESPECTADORES PARA
APLICAÇÕES DE SUGESTÃO DE CONTEÚDO EM *SMART* TVS**

Trabalho de Conclusão de Curso apresentado
à banca avaliadora do Curso de Engenharia
de Computação, da Escola Superior de
Tecnologia, da Universidade do Estado do
Amazonas, como pré-requisito para obtenção
do título de Engenheira de Computação.

Orientador(a): Profa. Dra. Elloá Barreto Guedes da Costa

Manaus – Novembro – 2018

Capítulo 1

Resultados e Discussão

1.0.1 Abordagem 1

A primeira abordagem de treinamento das CNNs constituiu na utilização das imagens da base de dados sem pré-processamento. Duas funções de ativação distintas: relu (introduz não linearidade),lrelu (usado na literatura ...) Não há utilização de pesos previamente calculados.

(...)

Considerando a abordagem descrita na solução proposta, os resultados preliminares da execução das CNNs aplicadas ao problema de estimação de idade a partir de uma imagem de face são apresentados a seguir.

Conforme mencionado na Seção ??, os primeiros treinamentos e testes compreenderam as arquiteturas canônicas LeNet e AlexNet com função de ativação *ReLU* na camada de saída, tendo como entrada as imagens do conjunto de dados sem normalização e equalização. Obedecendo ao método de validação cruzada *holdout* previamente mencionado, os resultados da etapa de teste foram obtidos, detalhados na Tabela 1.1.

Tabela 1.1: Resultados preliminares do treino e teste dos modelos propostos utilizando *ReLU* na camada de saída.

Modelo	Épocas	RMSE
LeNet	95	41.08
AlexNet	55	41.96

Ao observar as previsões realizadas para exemplos individuais, percebeu-se uma tendência destas redes após treinamento em preverem valores baixos, indicando possivelmente *underfitting* em virtude do *ReLU dying problem* (CLEVERT; UNTERTHINER; HOCHREITER, 2015; PEDAMONTI, 2018). Como alternativa, estes autores sugerem utilizar variantes da *ReLU* que não exibam saídas nulas, diferentes estratégias de inicialização e regularização de pesos e *batches*, entre outras. Como exposto na Seção ??, adotou-se a *Leaky ReLU* como função de ativação da camada de saída. Os resultados deste treinamento estão expostos na Tabela 1.2.

Tabela 1.2: Resultados preliminares do treino e teste dos modelos propostos utilizando *Leaky ReLU* na camada de saída.

Modelo	Épocas	RMSE
LeNet	12	41.55
AlexNet	6	14.38

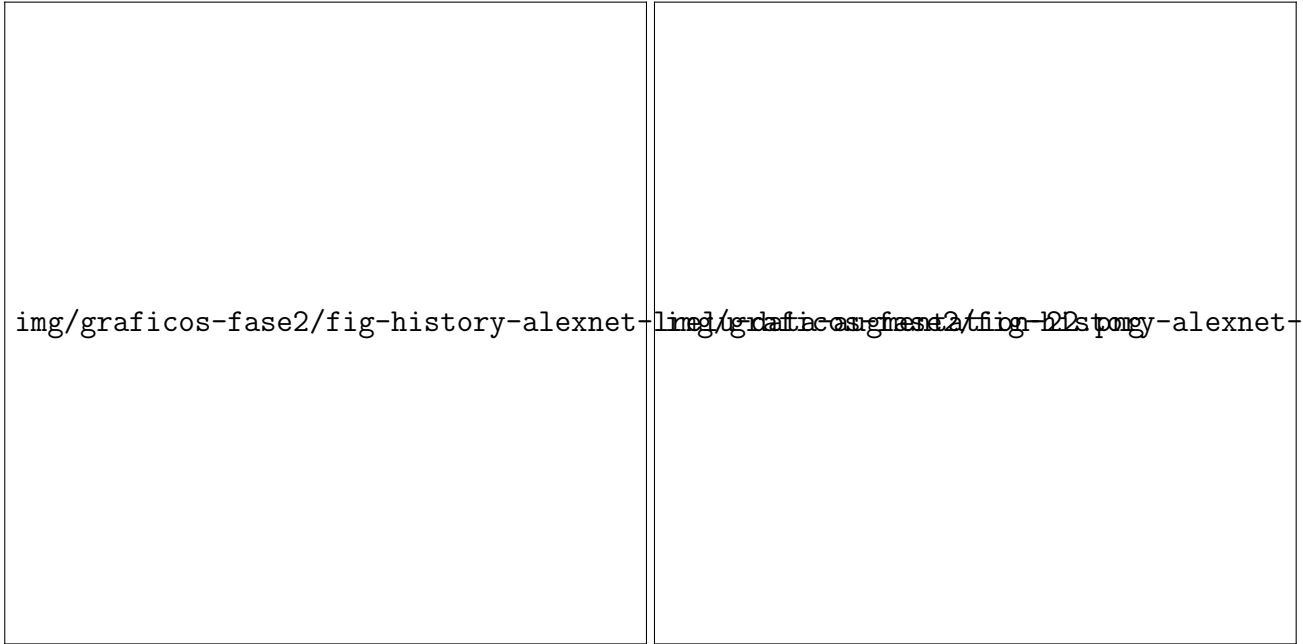
Observa-se que houve uma resposta positiva da AlexNet que melhorou a qualidade das previsões para o problema considerado. Porém, observa-se uma tendência desta rede em prever valores médios, o que ainda enseja melhorias. Assim, ainda é necessário investigar outros parâmetros e modelos para o problema em questão.

1.0.2 Abordagem 2

- Mesmas redes - Normalização das imagens, equalização por histograma -> o que é

Figura 1.1: Redes neurais biológicas.

(a) Treinamento Alexnet LRelU com imagens nor- (b) Treinamento Alexnet ReLU com imagens nor-
malizadas e equalizadas malizadas e equalizadas



(c) Treinamento LeNet ReLU com imagens norma-
lizadas e equalizadas

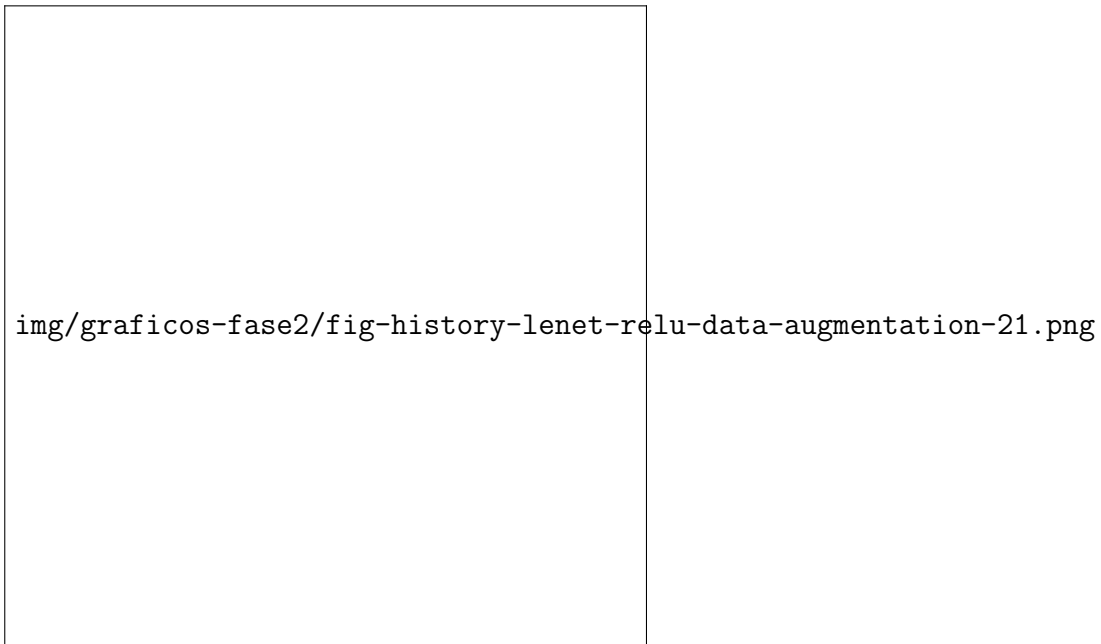



Figura 1.2: Redes neurais biológicas.

- (a) Reta-0 Alexnet LRelU com imagens normaliza-
das e equalizadas
- (b) Reta-0 Alexnet ReLU com imagens normaliza-
das e equalizadas
- (c) Reta-0 L
e equalizada



Figura 1.3: Redes neurais biológicas.

- (a) Diferença de previsões Alexnet LRelU com ima-
gens normalizadas e equalizadas
- (b) Diferença de previsões Alexnet ReLU com ima-
gens normalizadas e equalizadas
- (c) Diferenç
gens normal



Capítulo 2

Considerações Finais

O objetivo deste trabalho consiste em elaborar estratégias inteligentes para estimação de idade de telespectadores de *Smart* TVs a partir de suas respectivas fotografias faciais. Para este fim, foram propostos, treinados e testados em caráter preliminar dois modelos de CNNs já bem estabelecidos na literatura, a LeNet e AlexNet, com dois perfis de hiperparâmetros cada um.

Com isto, observou-se uma melhora significativa na performance da AlexNet, enquanto o RMSE da LeNet não sofreu grandes mudanças. Quanto às saídas das redes, a LeNet exibiu valores positivos e negativos próximos de zero, e a AlexNet forneceu previsões que giravam em torno da média dos dados. Estes resultados são preliminares e certamente outros modelos e parâmetros serão investigados conforme previsto na metodologia e cronograma deste trabalho de conclusão de curso.

Nos próximos meses, os esforços estarão concentrados em pesquisar e adotar estratégias que possam minimizar os problemas identificados, como substituir as funções de ativação das camadas ocultas por outras variantes da *ReLU*, adotar métodos específicos de inicialização de pesos, normalização de *batch*, entre outros. Planeja-se também a proposição, o treinamento e teste de outras redes inspiradas em outros modelos canônicos.

O problema em questão é importante do ponto de vista prático para o desenvolvimento de diversas soluções de recomendação de conteúdo e controle parental em *Smart* TVs, auxiliando no desenvolvimento destas soluções tecnológicas. Considerando a formação de uma bacharela

em Engenharia de Computação, endereçar este problema permite a prática de diversos conceitos vistos ao longo do curso, em especial relacionados às disciplinas de Inteligência Artificial, Redes Neurais, Processamento Digital de Imagens, *Machine Learning* e Sinais e Sistemas.

Referências Bibliográficas

CLEVERT, D.; UNTERTHINER, T.; HOCHREITER, S. Fast and accurate deep network learning by exponential linear units (elus). *CoRR*, abs/1511.07289, 2015. Disponível em: <<http://arxiv.org/abs/1511.07289>>.

PEDAMONTI, D. Comparison of non-linear activation functions for deep neural networks on MNIST classification task. *CoRR*, abs/1804.02763, 2018. Disponível em: <<http://arxiv.org/abs/1804.02763>>.